

Hw4: Support Vector Machine

Problem

你受聘為一家名叫 FutureBank 的資料分析實習生。

FutureBank 最近有點慘，每個月都有客戶突然關帳戶，或是轉去別家銀行。

主管開會氣到拍桌：「到底是誰把我們客戶都氣跑的！」

而你作為新進的資料實習生，被指派成「客戶流失偵探」。

主管丟給你一份神祕的檔案說：「這裡有客戶的資料，你幫我找出哪些人最有可能要落跑的！」

你小心翼翼問：「那…我們要怎麼知道誰會跑？」

主管皺眉：「你不是在修人工智慧嗎？SVM 什麼的都學過吧？」

你想一想：「對耶」

於是你從從容容遊刃有餘，準備開始進行一場「拯救銀行」的任務。

Dataset

- 本資料集的任務是根據客戶的個人與銀行帳戶資料，預測該客戶是否會流失。
請從作業區下載資料集，檔案格式皆為 .csv，第一行是 column 名稱，第二行開始則是每一位客戶的資料。
- 內容包含三個 split：train, test, validation（以下簡稱 val）：
 - train.csv、train_gt.csv — train split 的 input 與 ground truth：3200筆
 - val.csv、val_gt.csv — val split 的 input 與 ground truth：400筆
 - test.csv — test split 的 input：400筆
- 每個 column 的資料種類具體如下：

欄位名稱	類型	說明
RowNumber	int	資料編號
CustomerId	int	客戶編號
Surname	string	客戶姓氏
CreditScore	int	信用評分（數值越高代表信用越好）
Geography	string	客戶所在國家（France / Spain / Germany）
Gender	string	性別（Male / Female）

欄位名稱	類型	說明
Age	int	年齡
Tenure	int	客戶在銀行的年資（單位：年）
Balance	float	銀行帳戶餘額
NumOfProducts	int	使用的銀行產品數
HasCrCard	int	是否擁有信用卡（1=有，0=無）
IsActiveMember	int	是否為活躍客戶（1=活躍，0=非活躍）
EstimatedSalary	float	客戶估計年薪
Exited	int	目標變數：是否流失（1=流失，0=未流失）

Assignment Description

- 本次作業請使用 Python 3 完成。
- 本次作業請使用 Python 中 Machine Learning 開源套件：scikit-learn (sklearn) 提供的 Support Vector Machine (SVM) 來完成你的預測結果，套件下載指令如下：

```
pip install scikit-learn
```

- 本次作業分為五個步驟：

1. 了解資料

- 下載資料集，理解題目的意義。
- 參閱上述的 column 定義，也可以分析與統計各個 column 的資料，思考如何處理。

2. 前處理

- 由於有不同種的資料，在進行後續的模型預測之前，需要先將各種資料進行前處理，例如轉換成模型可以運算的型別、做資料視覺化幫助分析等等。
- 可以嘗試設計不同的前處理方式，來達到更高的準確度。

3. 建立與訓練模型

- 按照課堂上所學，應用 Support Vector Machine，以 training set 訓練，再對 validation set 與 testing set 進行預測。

4. 評估與優化

- 利用 validation set 進行預測與評分，想辦法提升準確度，例如調整模型的參數或是嘗試加上特殊的前處理方式。
- 我們有提供評估程式碼 `eval.py`，使用方法範例如下，假設輸出的預測結果為 `val_pred.csv`，對應 `val_gt.csv` 為答案，則計算 validation set 準確率的指令：

```
python eval.py val_gt.csv val_pred.csv
```

5. 輸出預測結果

- 請將 validation set `val.csv` 與 testing set `test.csv` 的預測結果分別儲存成 `val_pred.csv` 與 `test_pred.csv` 兩個 csv 檔。
- 格式的部分，第一行固定是 `Exited`，第二行開始是按照順序的預測結果 (1=流失 或 0=未流失)，如下方範例 (4筆資料)：

```
Exited
1
0
0
1
```

6. 撰寫心得報告

- 請根據作業檔案中提供的 `report.docx` 進行撰寫與修改。
- 報告內容如下
 - 資料前處理做法說明
 - 你使用了什麼樣的前處理方式
 - 資料視覺化圖表
 - 最後挑選了哪些欄位作為輸入
 - SVM 模型選擇說明
 - 怎麼挑選 SVM 的參數？
 - 為甚麼這樣挑選參數的效果會比較好或比較不好？
 - 比較兩種以上不同參數的 SVM 帶來的結果，並說明模型產生不同結果的原因

Notice

- 請使用 Python 3 完成作業，版本 ≥ 3.8 。
- 撰寫程式碼，變數命名必須有意義、須包含註解。
- **嚴禁抄襲，我們會使用比對工具檢查！**
- 有任何作業上的問題，請一律寄信到 **TA mail**：nckummcvlab@gmail.com

Submission

本次繳交期限到 2025-11-13 23:59，請務必於此期限內繳交完畢，逾期不開放補交

本次作業需要繳交以下檔案：

- svm.py — SVM 程式碼
- val_pred.csv — 對 val.csv 的預測結果
- test_pred.csv — 對 test.csv 的預測結果
- report.docx (或 report.pdf) — 本次的作業報告

將以上檔案如下方結構，壓縮成 **zip** 檔案，請命名為 **HW4_學號.zip** 再繳交，例如 **HW4_P12345678.zip**。

```
HW4_P12345678.zip
| svm.py
| val_pred.csv
| test_pred.csv
| report.docx (或 report.pdf)
```

！檔案名稱 與 檔案格式 請務必繳交正確的格式！若有錯誤，作業成績為0



我們只有提供 validation set 的答案讓同學測試，而 testing set 是隱藏測資